

Licenciatura en Gestión de Tecnologías de la Información

Sistemas Inteligentes 2026

TP INDIVIDUAL - ML Implementación de algoritmos de aprendizaje automático supervisado para regresión y clasificación Experimentando con distintos modelos

Objetivo: Aplicar algoritmos fundamentales de Machine Learning (Regresión y Clasificación), evaluar su rendimiento mediante métricas estándar.

Instrucciones Generales:

- Para cada parte, deberán crear un nuevo notebook de Jupyter/Colab.
- Pueden utilizar como base los códigos provistos en la cátedra (archivos 001 al 009) y códigos de presentaciones de clases.
- El trabajo debe incluir no solo el código funcional, sino también **celdas de texto (Markdown)** explicando qué hace el código, analizando los resultados y respondiendo a las preguntas planteadas.

Parte 1: Regresión Lineal Múltiple y Métricas de Error

Dataset: Costo Seguro Médico provisto en campus virtual. Predice el costo del seguro médico de una persona en función de su edad, género, IMC (BMI), cantidad de hijos y si fuma o no.

Dataset original: <https://www.kaggle.com/datasets/mirichoi0218/insurance>

Tarea: El objetivo es predecir el costo médico en función de sus características.

1. **Exploración y Preparación:** Carguen el dataset. Inspeccionar los primeros datos usando el método head. Seleccionen una variable (X) continua que consideren y la variable objetivo (y) que será el cargo (charges). Realicen un gráfico de dispersión (Scatter Plot).
2. **División de Datos:** Carguen el dataset y separen los datos en un conjunto de entrenamiento (80%) y un conjunto de prueba (20%) utilizando `train_test_split`.
3. **Entrenamiento:** Utilizando la librería `scikit-learn`, instancien y entrenen un modelo de `LinearRegression` con los datos seleccionados para realizar la regresión lineal múltiple.
4. **Predicción y Evaluación:**
 - Realicen predicciones sobre el conjunto de entrenamiento y conjunto de prueba.
 - Calculen el Error Absoluto Medio (MAE) y el Error Cuadrático Medio (MSE) sobre el conjunto de entrenamiento y prueba.
 - Probar escalando características.
5. **Análisis:**
 - ¿Qué significa el valor del MAE?
 - ¿Por qué el MSE es numéricamente mucho más grande que el MAE en este caso?
 - ¿Mejora algo al escalar características? ¿Por qué?

Parte 2: Clasificación (KNN y Árboles de Decisión)

Dataset: Insuficiencia cardíaca. Conjunto de datos para la predicción de insuficiencia cardíaca.

Dataset original: <https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction>

Tarea: El objetivo es clasificar correctamente la enfermedad cardíaca: clase de salida [1: enfermedad cardíaca, 0: normal].

1. **Exploración y Preparación:** Carguen el dataset. Inspeccionar los primeros datos usando el método `head`. Transformar las variables categóricas a variables ficticias.
2. **División de Datos:** Carguen el dataset y separen los datos en un conjunto de entrenamiento (80%) y un conjunto de prueba (20%) utilizando `train_test_split`.
3. **K-Nearest Neighbors (KNN):**
 - Entrenen un modelo `KNeighborsClassifier`.
 - Prueben con al menos tres valores diferentes de K (por ejemplo, 3, 5 y 11).
 - Calculen la Exactitud (*Accuracy*) y generen la Matriz de Confusión para el conjunto de prueba con el mejor valor de K.
4. **Árboles de Decisión (Decision Trees):**
 - Entrenen un modelo `DecisionTreeClassifier`.
 - Experimenten cambiando el hiperparámetro `max_depth` (profundidad máxima del árbol). ¿Qué sucede con la exactitud en entrenamiento vs. prueba si el árbol es muy profundo?
 - Grafiquen el árbol resultante utilizando `plot_tree`.
 - Calculen la Exactitud (*Accuracy*) y generen la Matriz de Confusión para el mejor modelo con el conjunto de prueba.
5. **Análisis Comparativo:**
 - Comparando las matrices de confusión de ambos algoritmos, ¿hubo alguna clase que a los modelos les costara más predecir correctamente?
 - ¿Cuál de los dos algoritmos (KNN o Árboles de Decisión) arrojó mejores resultados para este problema en particular?

Entregables esperados:

- Dos archivos `.ipynb` (regresión y clasificación) o enlace a Google Colab que contenga las dos partes resueltas.
- El código debe estar documentado.
- Las celdas de salida deben estar ejecutadas para poder visualizar los gráficos y métricas sin necesidad de correr el notebook desde cero.
- Fecha de entrega: domingo 24/05/2026 hasta las 23:59 hs.